



Université Iba Der THIAM de Thiès

UFR Sciences et Technologies

Département Mathématique

Master Sciences de Données et Applications option Statistiques et Econométrie

Option : Statistique Econométrie et Modélisation

Projet 2 de Statistiques des Valeurs Extrêmes

Nom des membres du groupe :

Ismael YODA

Amsatou DIOP

Mathiam FAYE

Nom du Professeur :

Dr Mouhamad ALLAYA

Année Scolaire 2020 & 2021

Exercices:

1...

Importation des données

```
data=read.csv2("C:/Users/YODA ISMAEL/Desktop/Dossier Etudes/Dossiers Master/Semestre3/Valeurs Extremes/d.csc9199.csv",sep = ";", dec=".",header=F,col.names = "log return")
head(data)
```

```
##    log.return
## 1      -2.539
## 2      -4.082
## 3      -3.021
## 4      -2.485
## 5       3.705
## 6      -0.608
```

Nos données étant en pourcentage, nous allons les diviser par cent(100) pour la suite de notre travail

```
data=data/100
```

Création d'un vecteur date contenant les jours de 1991 à 1999

```
DATE=seq(from = as.Date("1991-01-01"), to = as.Date("1999-12-31"), by = 1)
DATE=DATE[1:2275]
```

Nous constatons que la taille des données(2275), ne permet pas d'avoir une étendue de données allant 1991 à 1999. Pour que nos données couvrent cette étendue, il nous aurait fallu au moins 3285 observations. Avec 2275 observations, nos données s'étendent du 01 Janvier 1991 au 24 Mars 1997. C'est donc en considérant cette étendue des données que nous avons fait le travail.

Concaténation des vecteur DATE et data(qui représente nos données)

```
df=cbind(DATE,data)
head(df)
```


```
##      DATE log.return
## 1 1991-01-01 -0.02539
## 2 1991-01-02 -0.04082
## 3 1991-01-03 -0.03021
## 4 1991-01-04 -0.02485
## 5 1991-01-05  0.03705
## 6 1991-01-06 -0.00608
```

Représentation graphique des données

```
library(ggplot2)
```

```
graph <- ggplot(df, aes(x = DATE, ymax = log.return, ymin = 0)) +
  geom_linerange(col = "lightblue") +
  scale_x_date(date_labels = "%b-%Y") +
  ylab("Precipitation (mm)") +
  xlab("Date")
```

```
graph
```



Notre série semble stationnaire. Effectuons un test de stationnarité pour vérifier.

Nous allons utiliser le test de stationnarité de Dickey Fuller pour vérifier la stationnarité de la série des rendements logarithmiques négatifs.

```
library(tseries)
```

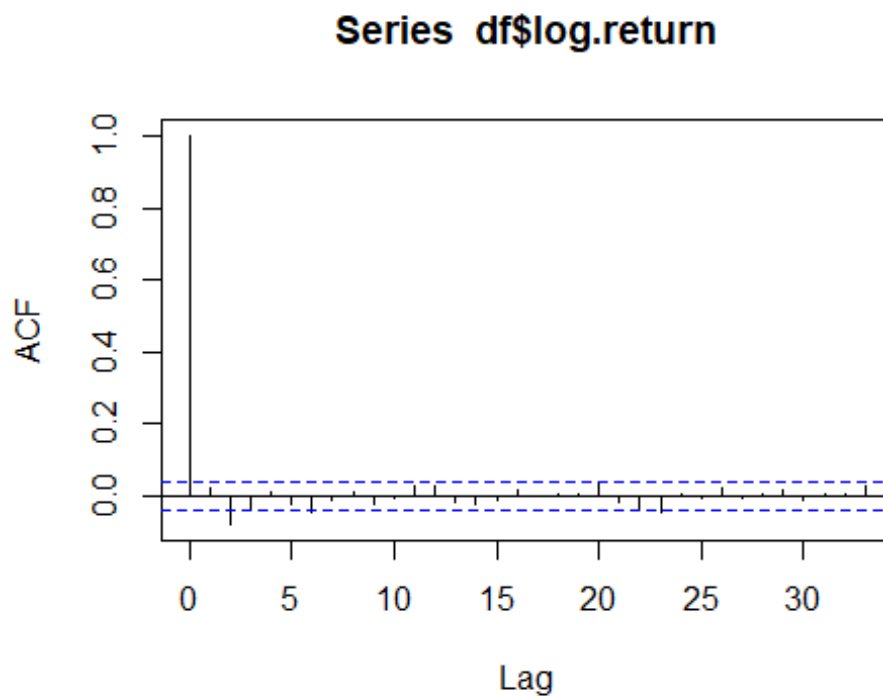
```
adf.test(df$log.return)
```

```
## Warning in adf.test(df$log.return): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: df$log.return
## Dickey-Fuller = -13.44, Lag order = 13, p-value = 0.01
## alternative hypothesis: stationary
```

D'après les résultats du test, la p-value est inférieure à tous les seuils conventionnels. Notre série des rendements logarithmiques négatifs est donc stationnaire.

Vérifions si il n'existe pas une autocorrélation de la série

```
acf(df$log.return)
```



La majorité des pics ne sont pas significatifs. Il n'existe donc pas d'autocorrélation de notre série.

Calculons la Value-at-Risk (VaR) de notre position, avec 95% intervalles de confiance si possible, pour le jour de bourse suivant en utilisant les probabilités $p=0,01$ et $p=0,005$ et les méthodes suivantes:

(a). Supposons que les retours logarithmiques soient normalement distribués

Avec $p=0,01$

```

mu=mean(df$log.return) # Moyenne des observations

ecart_type=sqrt(var(df$log.return)) # Ecart type des observations

z=qnorm((1-0.01),mean=mu,sd=ecart_type) # Quantile de la loi normal de probabilité (1-p)=0,99. Ceci correspond à la VaR_0.99. Cette valeur peut être utilisée pour calculer la mesure de risque du placement financier

VaR=z*1000000 # Value at Risk du placement financier
z
## [1] 0.06896071

VaR
## [1] 68960.71

```

Le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à 68960,71 \$ sous une probabilité de 0,99.

Avec $p=0,005$

```

mu=mean(df$log.return) # Moyenne des observations

ecart_type=sqrt(var(df$log.return)) # Ecart type des observations

z=qnorm((1-0.005),mean=mu,sd=ecart_type) # Quantile de la loi normal de probabilité (1-p)=0,99. Ceci correspond à la VaR_0.99. Cette valeur peut être utilisée pour calculer la mesure de risque du placement financier

VaR=z*1000000 # Value at Risk du placement financier
z
## [1] 0.07608087

VaR
## [1] 76080.87

```

Le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à 76080,87 \$ sous une probabilité de 0,995.

(b). Utilisons un modèle GARCH(1,1) avec une distribution gaussienne conditionnelle

Estimation du modèle GARCH(1,1)

```

library(fGarch)

mod1=garchFit(~garch(1,1),data=df$log.return,trace=F) # Estimation du modèle
## Warning: Using formula(x) is deprecated when x is a character vector of length > 1.
## Consider formula(paste(x, collapse = " ")) instead.

```

```
predict(mod1,3)# Estimation de la moyenne et de l'écart type du modèle  
GARCH(1,1)
```

```
##      meanForecast meanError standardDeviation  
## 1  0.003278439 0.02094808      0.02094808  
## 2  0.003278439 0.02130978      0.02130978  
## 3  0.003278439 0.02165235      0.02165235
```

Calcul de la VaR avec $p=0.01$

```
z=qnorm((1-0.01),mean=0.003278439,sd=0.02094808) # VaR_0.99  
VaR=z*1000000 # Value at Risk du placement financier  
z  
## [1] 0.05201096  
VaR  
## [1] 52010.96
```

En supposant un modèle GARCH(1,1) avec une distribution gaussienne conditionnelle, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à 52010,96 \$ sous une probabilité de 0,99.

Calcul de la VaR avec $p=0.005$

```
z=qnorm((1-0.005),mean=0.003278439,sd=0.02094808) # VaR_0.995  
  
VaR=z*1000000 # Value at Risk du placement financier  
z  
## [1] 0.05723712  
VaR  
## [1] 57237.12
```

En supposant toujours un modèle GARCH(1,1) avec une distribution gaussienne conditionnelle, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à 57237,12 \$ sous une probabilité de 0,995.

(c).Utilisons un modèle GARCH(1,1) avec une distribution conditionnelle Student-t, où vous estimez les degrés de liberté.

Estimation du modèle GARCH(1,1)

```

library(fGarch)
mod2=garchFit(~garch(1,1),data=df$log.return,trace=F,cond.dist="std") # Estimation du modèle

mod2

##
## Title:
## GARCH Modelling
##
## Call:
## garchFit(formula = ~garch(1, 1), data = df$log.return, cond.dist = "std",
## trace = F)
##
## Mean and Variance Equation:
## data ~ garch(1, 1)
## <environment: 0x0000000020c0f208>
## [data = df$log.return]
##
## Conditional Distribution:
## std
##
## Coefficient(s):
##      mu      omega    alpha1    beta1    shape
## 3.1733e-03 3.7547e-05 6.9806e-02 8.8243e-01 9.6640e+00
##
## Std. Errors:
## based on Hessian
##
## Error Analysis:
##      Estimate Std. Error t value Pr(>|t|)
## mu      3.173e-03 5.322e-04 5.963 2.48e-09 ***
## omega  3.755e-05 1.477e-05 2.542 0.01101 *
## alpha1 6.981e-02 1.805e-02 3.867 0.00011 ***
## beta1  8.824e-01 3.290e-02 26.825 < 2e-16 ***
## shape  9.664e+00 1.590e+00 6.078 1.22e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 4982.424 normalized: 2.190076
##
## Description:
## Thu Sep 09 20:07:09 2021 by user: YODA ISMAEL

predict(mod2,3)# Estimation de La moyenne et de L'écart type du modèle
GARCH(1,1)

## meanForecast meanError standardDeviation
## 1 0.003173322 0.02160053 0.02160053

```

```
## 2 0.003173322 0.02195099 0.02195099
## 3 0.003173322 0.02227960 0.02227960
```

Calcul de la VaR avec $p=0.01$ et avec un degré de liberté égal à 9,664 (représente la valeur du paramètre shape)

```
z=0.003173322+qt(0.99,9.664)*0.02160053 # VaR_0.99
VaR=z*1000000 # Value at Risk du placement financier
z
## [1] 0.06325727
VaR
## [1] 63257.27
```

En supposant un modèle GARCH(1,1) avec une distribution conditionnelle Student-t et un degré de liberté estimé de 9,664, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximale de perte journalière évalué à 63257,27\$ sous une probabilité de 0,99.

Calcul de la VaR avec $p=0.005$ et avec un degré de liberté égal à 9.664

```
z=0.003173322+qt(0.995,9.664)*0.02160053 # VaR_0.995
VaR=z*1000000 # Value at Risk du placement financier
z
## [1] 0.07216805
VaR
## [1] 72168.05
```

En supposant toujours un modèle GARCH(1,1) avec une distribution conditionnelle Student-t et un degré de liberté estimé de 9,664, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximale de perte journalière évalué à 72168,05\$ sous une probabilité de 0,995.

(d).Utilisons le quantile d'échantillon inconditionnel des retours de log (simulation historique)

Calcul de la VaR avec $p=0.01$

```
z=quantile(df$log.return,(1-0.01)) # VaR_0.99
VaR=z*1000000 # Value at Risk du placement financier
z
```



```
##          99%
## 0.0725778
```

VaR

```
##          99%
## 72577.8
```

En utilisant le quantile d'échantillon inconditionnel des retours de log, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximale de perte journalière évalué à 72577,8\$ sous une probabilité de 0,99.

calcul de la VaR avec $p=0.005$

```
z=quantile(df$log.return,(1-0.005)) # VaR_0.995
```

```
VaR=z*1000000 # Value at Risk du placement financier
```

z

```
##          99.5%
## 0.0811779
```

VaR

```
##          99.5%
## 81177.9
```

En utilisant le quantile d'échantillon inconditionnel des retours de log, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à 81177,9 \$ sous une probabilité de 0,995.

(e). Utilisons la théorie des valeurs extrêmes pour le maximum du retour journalier négatif. Utilisons des blocs trimestriels pour estimer la distribution et l'utilisation du GEV l'équation (7.26) de Tsay pour calculer la VaR.

Nous Estimerons du modèle GEV en utilisant 47 blocs car nous avons 2275 jour ce qui équivaut à 190 mois donc à 48 trimestres. Nous allons utiliser la library "fExtremes" pour le calcul de nos maximums et la library "evd" pour la modélisation de nos valeurs extrêmes.

Déterminons les maximums de chaque block

```
library(fExtremes)
```

```
max_trimestre=blockMaxima(as.timeSeries(df$log.return), block = 48)
head(max_trimestre)
```

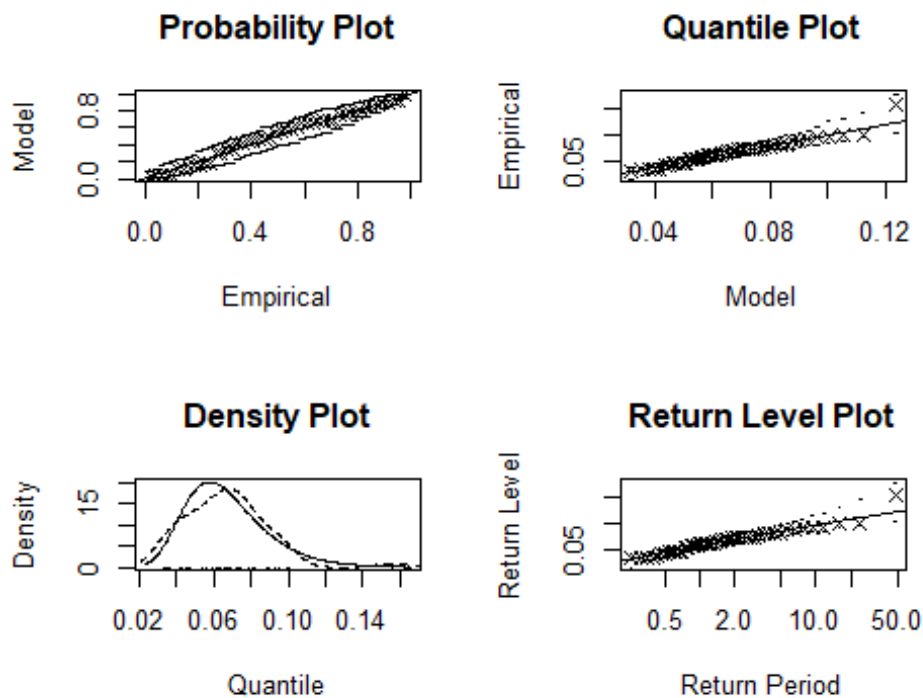
```
## GMT
##    max.SS.1 from* to* SS.1*
## 1  0.07260    1  48    10
## 2  0.15576   49  96    63
## 3  0.05579   97 144   126
```

```
## 4  0.06718  145 192  162
## 5  0.06933  193 240  217
## 6  0.07889  241 288  268
```

Estimation du modèle GEV et représentation graphique

```
library(evd)

fit0=fgev(max_trimestre$max.SS.1) # Estimation du modèle
par(mfrow=c(2,2))
plot(fit0)
```



En observant le Quantile Plot, le modèle semble globalement bien ajusté

Estimation des paramètres μ , σ et ζ du modèle GEV

```
fit0$param # Parametres du modèle

##          loc          scale          shape
## 0.05707406 0.01828846 -0.03516504
```

Supposons qu'il s'agit d'une distribution de Gumbel c'est à dire que $\zeta = 0$

```
fit1=fgev(max_trimestre$max.SS.1, shape=0)
fit1$param
```

```
##      loc      scale      shape
## 0.05671166 0.01811063 0.00000000
```

Test anova pour comparer les deux modèles. L'hypothèse nulle est que le modèle "fit1" est meilleur que "fit0"

```
anova(fit0,fit1)
```

```
## Analysis of Deviance Table
##
##      M.Df Deviance Df  Chisq Pr(>chisq)
## fit0     3   -235.36
## fit1     2   -235.24  1  0.1279      0.7207
```

La p-value du test supérieure à tous les seuils conventionnels. On ne peut donc pas rejeter l'hypothèse nulle. Le modèle "fit1" sera préféré au modèle "fit0". Nous sommes donc face à une distribution de Gumbel.

Calcul de la VAR avec l'équation de Tsay avec $p=0.01$ et avec $\zeta = 0$

```
z=mean(max_trimestre$max.SS.1)-sd(max_trimestre$max.SS.1)*log(-48*(log(1-0.01))) # VaR_0.99
```

```
VaR=z*1000000 # Value at Risk du placement financier de 1million de dollars
z
```

```
## [1] 0.08333226
```

```
VaR
```

```
## [1] 83332.26
```

En utilisant des blocs trimestriels pour estimer la distribution avec un modèle GEV et l'équation de Tsay pour calculer la VaR, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximale de perte journalière évalué à 83332,26\$ sous une probabilité de 0,99.

Calcul de la VAR avec l'équation de Tsay avec $p=0.005$ et avec $\zeta = 0$

```
z=mean(max_trimestre$max.SS.1)-sd(max_trimestre$max.SS.1)*log(-48*(log(1-0.005))) # VaR_0.99
```

```
VaR=z*1000000 # Value at Risk du placement financier de 1million de dollars
z
```

```
## [1] 0.09903844
```

```
VaR
```

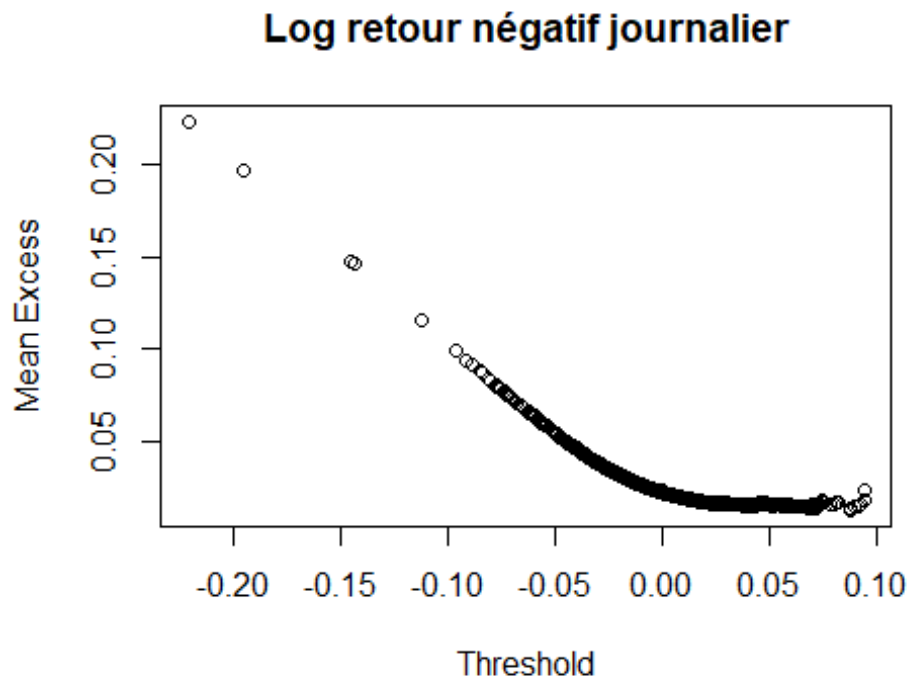
```
## [1] 99038.44
```

En utilisant des blocs trimestriels pour estimer la distribution avec un modèle GEV et l'équation de Tsay pour calculer la VaR, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximale de perte journalière évalué à 99038,44\$ sous une probabilité de 0,995.

(f). Utilisons la théorie des valeurs extrêmes pour les dépassements de seuils (pics au-dessus des seuils) sur la base des rendements journaliers négatifs. Utilisons les tracés d'excès de moyenne empirique pour déterminer la valeur seuil appropriée pour la distribution de Pareto généralisée (GPD) puis ajustons le modèle par maximum de vraisemblance. Calculons la VaR et Intervalles de confiance à 95 % en utilisant la fonction riskmesures. Traçons l'intervalle de confiance à 95% en utilisant les fonctions tailplot and gdp.q. Enfin, examinons la sensibilité des estimations de VaR aux variations du seuil avec la fonction quant.

Les tracés d'excès de moyenne empirique.

```
library(evir)
meplot(df$log.return)
title(main="Log retour négatif journalier")
```



D'après le tracé ci-dessus, la valeur seuil appropriée pour la distribution de Pareto généralisée (GPD) peut être estimée à 0,05.

Estimation du modèle par maximum de vraisemblance

```

model= pot(df$log.return,threshold=0.05)
model

## $n
## [1] 2275
##
## $period
## [1] 1 2275
##
## $data
## [1] 0.07260 0.05855 0.05743 0.05407 0.06062 0.09180 0.05827 0.15576 0.071
29
## [10] 0.06959 0.08841 0.05579 0.06718 0.06933 0.07320 0.07889 0.05097 0.073
69
## [19] 0.05837 0.05157 0.05317 0.06121 0.05269 0.08097 0.05423 0.07450 0.050
12
## [28] 0.05246 0.05407 0.06364 0.05619 0.05407 0.10073 0.07267 0.05245 0.055
06
## [37] 0.09453 0.06968 0.07613 0.05236 0.08130 0.05218 0.05349 0.06174 0.055
06
## [46] 0.06454 0.06552 0.06032 0.06606 0.07469 0.05179 0.05919 0.07917 0.055
86
## [55] 0.08249 0.05339 0.05615 0.07411 0.09899 0.05643 0.06652 0.06313 0.056
23
## [64] 0.06252 0.05170 0.06493 0.08983 0.05039 0.06768 0.07257 0.07009 0.054
88
## [73] 0.06588 0.09328 0.05628 0.05153 0.09462 0.05848 0.05229 0.06213 0.069
80
## [82] 0.08831 0.06266 0.05827 0.05642 0.06348 0.05365 0.05123 0.06208 0.060
88
## [91] 0.05964 0.05422 0.06885 0.06832 0.05208
## attr(,"times")
## [1] 10 14 18 50 53 55 60 63 70 73 74 126 162 217
250
## [16] 268 347 357 358 378 472 504 544 565 588 595 608 630 645
681
## [31] 686 702 704 722 823 825 837 843 855 858 873 881 893 896
905
## [46] 918 925 948 949 979 1002 1097 1111 1170 1172 1193 1213 1242 1257
1272
## [61] 1278 1309 1344 1477 1482 1548 1577 1583 1584 1600 1603 1615 1697 1727
1740
## [76] 1769 1939 1943 1954 1965 1966 1970 1974 1994 2002 2015 2033 2041 2051
2098
## [91] 2113 2129 2176 2240 2241
##
## $span
## [1] 2274
##
## $threshold

```

```
## [1] 0.05
##
## $p.less.thresh
## [1] 0.9582418
##
## $n.exceed
## [1] 95
##
## $run
## [1] NA
##
## $par.ests
##          xi          sigma          mu          beta
## -0.0055789936  0.0160080560 -0.0003840005  0.0157269640
##
## $par.ses
##          xi          sigma          mu
## 0.064653004 0.004194629 0.008742341
##
## $varcov
##          [,1]          [,2]          [,3]
## [1,] 0.0041800109 -2.527186e-04 4.611583e-04
## [2,] -0.0002527186 1.759491e-05 -3.517163e-05
## [3,] 0.0004611583 -3.517163e-05 7.642853e-05
##
## $intensity
## [1] 0.04177661
##
## $nllh.final
## [1] 96.64924
##
## $converged
## [1] 0
##
## attr("class")
## [1] "potd"
```

Calcul de la VaR et intervalles de confiance à 95 % en utilisant la fonction riskmesures et avec $p=0.01$ et $p=0.005$

```
VaR_0.99_0.995=riskmesures(model,c((1-0.01),(1-0.005))) # Ceci représente Les quantiles ou (VaR_0.99 et VaR_0.995)
```

```
VaR_0.99_0.995
```

```
##          p    quantile      sfall
## [1,] 0.990 0.07238935 0.08790484
## [2,] 0.995 0.08318298 0.09863859
```

Calcul des VaR du placement financier de 1 millions de dollars de Cisco

```
VaR1=1000000*0.07238935 # VaR du placement financier Cisco avec p=0.01
VaR2=1000000*0.08318298 # VaR du placement financier Cisco avec p=0.005
VaR1

## [1] 72389.35


VaR2

## [1] 83182.98
```

En utilisant la théorie des valeurs extrêmes pour les dépassements de seuils (peaks over threshold) sur la base des rendements journaliers négatifs, le placement financier de Cisco évalué à 1 millions de dollars, encoure un risque maximal de perte journalière évalué à respectivement 72389,35 \$ et 83182,98 sous les probabilités de 0,99 et 0,995.


Représentation graphique des intervalles de confiance la distribution de Pareto généralisée (GPD) en utilisant les fonctions tailplot.

```
tailplot(model)
```



Examinons la sensibilité des estimations de VaR aux variations du seuil avec la fonction quant

```
quant(df$log.return)
```



Nous constatons à travers le graphique ci-dessus que la VaR est sensible à la variation du seuil car une évolution du seuil entraîne également celle de la VaR.

2. Combinons GARCH et EVT. Cet exercice vous guide tout au long du processus de combiner GARCH avec EVT selon les lignes décrites dans McNeil et Frey(2000), « *Estimation of Tail-Related Risk Measures for Heteroskedastic Financial Time Series: An Extreme Value Approach* », *Journal of Empirical Finance*. Voir aussi le document de cours de Bingcheng Yan. Pour cet exercice, utilisons les données sur Cisco log retour de l'exercice précédent et supposons que nous détenons une position longue de l'Action Cisco évaluée à 1 million de dollars

(a).Ajustons un modèle AR(1)-GARCH(1,1), avec des erreurs gaussiennes, aux log retours négatifs de l'action Cisco

Estimation du modèle AR(1)-GARCH(1,1)

```
library(fGarch)
garch=garchFit(~arma(1,0)+garch(1,1),data=df$log.return,trace=F) # Estimation
du modèle
```

```
garch
```

```
##
```

```
## Title:
```

```
## GARCH Modelling
```



```
##
## Call:
## garchFit(formula = ~arma(1, 0) + garch(1, 1), data = df$log.return,
##          trace = F)
##
## Mean and Variance Equation:
## data ~ arma(1, 0) + garch(1, 1)
## <environment: 0x000000001fd18940>
## [data = df$log.return]
##
## Conditional Distribution:
## norm
##
## Coefficient(s):
##          mu          ar1          omega          alpha1          beta1
## 3.1850e-03 3.5755e-02 3.2821e-05 8.1773e-02 8.7960e-01
##
## Std. Errors:
## based on Hessian
##
## Error Analysis:
##      Estimate Std. Error t value Pr(>|t|)
## mu      3.185e-03 5.462e-04 5.832 5.49e-09 ***
## ar1     3.575e-02 2.222e-02 1.609 0.1076
## omega   3.282e-05 1.190e-05 2.759 0.0058 **
## alpha1  8.177e-02 1.934e-02 4.227 2.37e-05 ***
## beta1   8.796e-01 3.007e-02 29.247 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 4949.388 normalized: 2.175555
##
## Description:
## Thu Sep 09 20:07:12 2021 by user: YODA ISMAEL
```

Valeurs prédites de mu_chapeau et sigma_chapeau

```
predict(garch,3)
```

```
## meanForecast meanError standardDeviation
## 1 0.003499251 0.02087056 0.02087056
## 2 0.003310081 0.02126343 0.02125033
## 3 0.003303317 0.02162251 0.02160914

mu_chapeau=0.003499251
sigma_chapeau=0.02087056
```

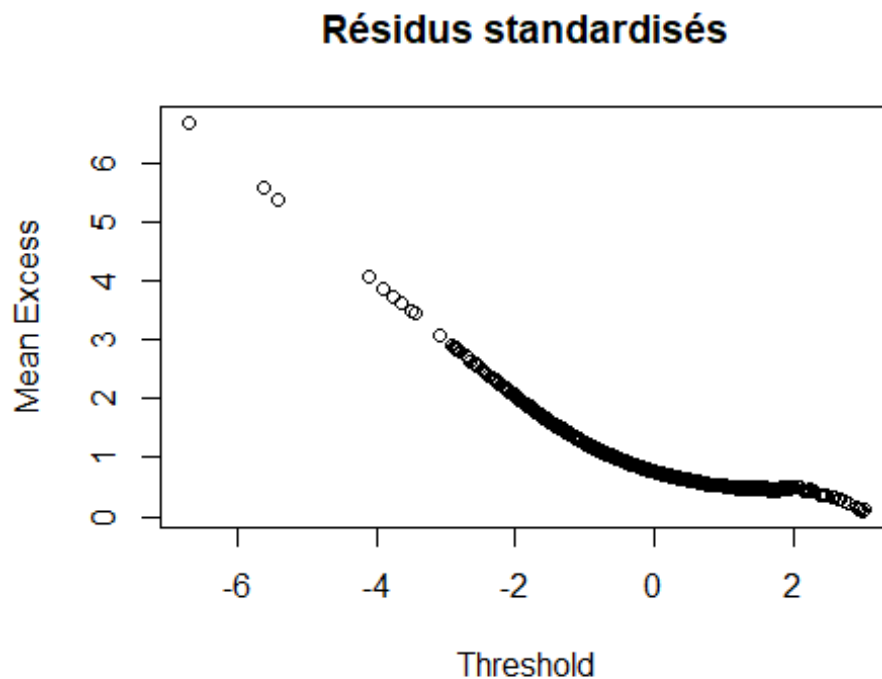
(b) Ajustons un GPD aux résidus standardisés estimés Z_t .

Récupérons d'abord des résidus standardisés $Z_t = \hat{\epsilon}_t / \hat{\sigma}_t$ du modèle

```
Zt=residuals(garch,standardize=T)
```

Déterminons le seuil qu'il faut considérer pour l'estimation du modèle

```
library(evir)
meplot(Zt)
title(main="Résidus standardisés")
```



D'après le tracé ci-dessus, la valeur seuil appropriée pour la distribution de Pareto généralisée (GPD) peut être estimée à 2.

Estimation du modèle GPD avec un seuil de 2.

```
model3=pot(Zt,threshold=2)
model3

## $n
## [1] 2275
##
## $period
## [1] 1 2275
##
## $data
```

```

## [1] 2.662694 2.297903 2.950981 2.441099 2.557771 2.732386 2.392637 2.8850
32
## [9] 2.208562 2.783429 3.094494 2.239574 2.008231 2.996878 2.398568 3.0101
98
## [17] 2.011362 2.214303 2.138716 2.186885 2.446497 2.161407 2.988330 2.0471
53
## [25] 2.178369 3.237061 2.224478 2.922064 2.004900 2.572645 3.050343 2.2288
76
## [33] 2.368159 2.723818 2.191905 2.467816 2.547970 2.042326 2.077984 2.6487
57
## [41] 2.455565
## attr(,"times")
## [1] 10 55 63 162 217 250 268 357 472 504 565 595 630 704
722
## [16] 837 843 873 918 925 948 949 979 1070 1097 1111 1170 1172 1193
1242
## [31] 1257 1309 1477 1577 1600 1697 1727 1994 2015 2176 2240
##
## $span
## [1] 2274
##
## $threshold
## [1] 2
##
## $p.less.thresh
## [1] 0.981978
##
## $n.exceed
## [1] 41
##
## $run
## [1] NA
##
## $par.ests
## xi sigma mu beta
## -0.6345964 10.3925130 -13.0957341 0.8128138
##
## $par.ses
## xi sigma mu
## 2.000214e-06 1.107334e+00 1.726069e+00
##
## $varcov
## [,1] [,2] [,3]
## [1,] 4.000856e-12 -6.232865e-10 8.338015e-10
## [2,] -6.232865e-10 1.226188e+00 -1.910555e+00
## [3,] 8.338015e-10 -1.910555e+00 2.979314e+00
##
## $intensity
## [1] 0.0180299
##

```

```
## $nllh.final
## [1] 212.1537
##
## $converged
## [1] 0
##
## attr(,"class")
## [1] "potd"
```

(c). En utilisant le modèle GPD, estimons le quantile z_q et la moyenne conditionnelle $E[Z|Z > z_q]$ pour $q = 0.01, 0.005$.

Estimations du quantile z_q pour $q = 0.01$ et $q = 0.005$

```
z_0.01_0.005=riskmeasures(model3,c((1-0.01),(1-0.005))) # Ceci représente les
quantiles ou z_0.01
et z_0.005
z_0.01_0.005

##          p quantile      sfall
## [1,] 0.990 2.399458 2.741634
## [2,] 0.995 2.713122 2.933524
```

estimations de la moyenne conditionnelle $E[Z|Z > z_q]$ pour $q = 0.01$ et $q = 0.005$

```
print(mean(Zt | Zt>2.399458)) # E[Z|Z > z_0.01]
## [1] 0.9995604
print(mean(Zt | Zt>2.713122)) # E[Z|Z > z_0.005]
## [1] 0.9995604
```

(d) A l'aide des estimations de z_q et de $E[Z|Z > z_q]$, calculons les estimations du quantile et de la moyenne conditionnelle de X_t

```
xt_plusun_0.01=mu_chapeau+sigma_chapeau*2.399458 # xt+1_chapeau,0.01
xt_plusun_0.005=mu_chapeau+sigma_chapeau*2.713122 # xt+1_chapeau,0.005
E_condit_xt_plusun_0.01=mu_chapeau+sigma_chapeau*0.9995604 #E[Xt+1|Xt+1>xt+1,
0.01]_chapeau
E_condit_xt_plusun_0.005=mu_chapeau+sigma_chapeau*0.9995604#E[Xt+1|Xt+1>xt+1,
0.005]_chapeau
xt_plusun_0.01

## [1] 0.05357728
xt_plusun_0.005

## [1] 0.06012363
E_condit_xt_plusun_0.01
```

```
## [1] 0.02436064
E_condit_xt_plusun_0.005
## [1] 0.02436064
```

(e) A partir des quantiles et des moyennes conditionnelles calculés précédemment, calculez les VaRq et ESq pour une position longue de 1 million de dollars sur l'action Cisco

```
VaR_0.01=(mu_chapeau+sigma_chapeau*(xt_plusun_0.01))*1000000
# VaR calculée nutilisant le quantile x_t+1_chapeau,0.01

VaR_0.005=(mu_chapeau+sigma_chapeau*(xt_plusun_0.005))*1000000
#VaR calculée en utilisant le quantile x_t+1_chapeau,0.005

VaR_0.01.= mu_chapeau+sigma_chapeau*(E_condit_xt_plusun_0.01)*1000000
#VaR calculée en utilisant l'espérance conditionnelle  $E[X_{t+1}|X_{t+1}>x_{t+1},0.01]$ _chapeau

VaR_0.005.= mu_chapeau+sigma_chapeau*(E_condit_xt_plusun_0.005)*1000000
#VaR calculée en utilisant l'espérance conditionnelle  $E[X_{t+1}|X_{t+1}>x_{t+1},0.005]$ _chapeau

VaR_0.01
## [1] 4617.439
VaR_0.005
## [1] 4754.065
VaR_0.01.
## [1] 508.4236
VaR_0.005.
## [1] 508.4236
```

(f) Comparons les résultats avec ceux de l'exercice 1.

En comparaison aux résultats trouvés dans l'exercice 1, nous pouvons dire les modèles utilisés dans l'exercice 1 donnent des valeurs assez élevées de la VaR. Nous pouvons donc penser que ces modèles conduisent à une surévaluation de la VaR réelle alors que le modèle combinant les ARMA-GARCH et EVT, donnent des valeurs beaucoup plus réalistes.